2025 年全国大学生计算机系统能力大赛
智能计算创新设计赛（先导杯）

MoE 语言模型端到端效率优化赛题
技术方案

一、赛题概述与基本要求

第 1 条 Mixture of Experts（MoE）是一种高效的大规模深度学习模型架构，通过动态路由机制使模型在推理和训练时只激活部分专家网络，从而降低计算量并提升性能。然而，MoE 模型的高效运行通常依赖于硬件加速器的支持，但由于专家路由的非均匀性、显存占用和通信开销等问题，MoE 模型在加速器上的推理效率仍面临挑战。

第 2 条 大赛要求参赛者使用指定国产 X86 处理器及其加速卡，对给定的预训练 MoE 语言模型（如 Mixtral-8×7B）进行部署优化，并使用提供的测试脚本和数据集，实现多项性能指标的优化提升。

第 3 条 MoE 模型的性能优化涉及多方面因素，参赛者需要根据模型特点和国产加速卡特性，分析性能瓶颈，采取针对性优化策略，包括但不限于专家路由策略、内存管理、计算并行化、模型量化技术等，以提升模型在指定国产加速卡上的推理效率和显存使用效率。

第 4 条 参赛者需提供完整的源码以进行评测，评测将使用 wikitext-103-v1 测试数据集，从推理延迟、显存占用和困惑度三个方面进行综合评估。优化后的模型应在保持困惑度上升不超过 15%的前提下，显著降低推理延迟与显存占用。

二、挑战维度

第 5 条 本赛题聚焦于专家层面的优化，其挑战维度如下：

1. 专家计算与路由优化

（1）自适应负载均衡策略：通过基于内容的动态路由机制，实现专家资源的自适应分配，避免专家过载或闲置，提高整体资源利用效率。

（2）专家分层协同决策机制：构建分层协同决策框架，配合自适应融合

技术，根据任务特性动态调整专家权重，增强模型对复杂任务的处理能力。

2. 资源与部署优化

（1）参数分片与高效缓存策略：通过参数分片存储与高效缓存等策略，优化显存使用方式，降低峰值显存占用，提高指定国产加速卡内存利用率。

（2）模型结构化稀疏与剪枝技术：采用动态稀疏激活技术，使简单输入仅激活少量专家，复杂输入调用更多专家参与推理；结合结构化剪枝与参数共享策略，降低冗余计算与模型规模。

3. 专家通信优化

（1）量化压缩与混合精度技术：根据专家重要性实施差异化量化策略，对关键通道保持较高的量化精度，次要通道采用较低的量化精度，平衡性能与通信带宽需求。

（2）异步执行与通信带宽优化：实现计算与通信的重叠机制，使专家计算与参数传输并行执行；采用拓扑感知的通信调度，基于硬件网络结构特性优化专家分布和通信模式，减少通信瓶颈。

三、初赛评分标准

第 6 条 初赛评价指标

1. 初赛依据平均单句推理延迟这一客观指标进行计分，但需满足困惑度上升不超过 15%。
2. 基于大赛提供的硬件平台，运行测试数据集（wikitext-103-v1），计算优化前后的平均单句推理延迟（单位：秒），精确到小数点后 4 位。计算公式如下：

$$\text{平均单句推理延迟} = \frac{\sum_{i=1}^{N} \text{推理延迟}_i}{N}$$

其中，N 为测试数据集的句子数量。

第 7 条 初赛评分细则

1. 推理效率优化效果（100 分）：

（1）参赛者优化后模型的困惑度必须控制在优化前模型困惑度的 15%以内，否则计 0 分。

（2）在困惑度上升不超过 15%的前提下，采用相对排名评分方式，实现最低平均单句推理延迟的参赛者获得满分 100 分，其他参赛者得分按以下公式计算：

$$得分 = \frac{优化前延迟 - 当前参赛者优化后延迟}{优化前延迟 - 最佳参赛者优化后延迟} \times 100$$

（3）若参赛者优化后的延迟大于或等于优化前的延迟，此项得分为 0 分。

2. 初赛总成绩 = 推理效率优化效果得分

四、决赛评分标准

第 8 条 决赛评价指标

在初赛的基础上，全面评估技术方案的创新性、推理效率、显存占用以及困惑度保持程度。包含以下四项指标：

1. 技术方案创新性：从优化方法的创新性、实现难度、可扩展性等方面进行评分。
2. 推理效率：计算平均单句推理延迟，单位为秒，精确到小数点后 4 位。
3. 显存占用：监测优化前后模型在推理过程中的显存占用峰值，单位为 GB，精确到小数点后 2 位。
4. 困惑度（Perplexity）：计算优化前后模型在测试数据集上的困惑度，精确到小数点后 4 位。

第 9 条 决赛评分细则

1. 推理效率优化效果（30 分）：

（1）采用相对排名评分方式，实现最低平均单句推理延迟的参赛者获得满分 30 分。

（2）其他参赛者得分按以下公式计算：

$$推理效率得分 = \frac{优化前延迟 - 当前参赛者优化后延迟}{优化前延迟 - 最佳参赛者优化后延迟} \times 30$$

（3）若参赛者优化后的延迟大于或等于优化前的延迟，此项得分为 0 分。

2. 显存占用优化效果（25 分）：

（1）评分采用相对排名方式，实现最低显存占用的参赛者获得满分 25 分。

（2）其他参赛者得分按以下公式计算：

$$显存占用得分 = \frac{优化前显存 - 当前参赛者优化后显存}{优化前显存 - 最佳参赛者优化后显存} \times 25$$

（3）若参赛者优化后的显存占用大于或等于优化前的显存占用，此项得分为 0 分。

3. 困惑度保持程度（25 分）：

（1）优化后的模型困惑度上升应控制在 15%以内。

（2）困惑度上升（或下降）0%为 25 分，0%～15%线性递减，≥15%为 0 分。若困惑度上升幅度在 0%至 15%之间，则计算公式为：

25-(实测困惑度上升百分比/15%×25)。

4. 技术方案创新性、设计文档及现场答辩表现（20 分）：

（1）从优化方法的创新性、实现难度、可扩展性等方面进行评分。

（2）创新性强、实现难度适中且可扩展性好的方案将获得较高评价。

（3）设计文档的完整性、清晰度和现场答辩的表现也将纳入考量。

五、参赛作品提交

第 10 条 参赛选手需在初赛和决赛阶段提交以下内容：

1. 完整源代码：包含所有必要的依赖项和配置文件，代码规范，确保在指定环境中能够顺利运行。代码需具有良好的注释和清晰的结构，便于评审人员理解和复现。
2. 优化说明文档：包含算法原理、优化思路、性能瓶颈分析、编译运行说明及第三方库使用说明以及运行结果。运行结果包含数据集的推理延迟、显存占用和困惑度的详细数据；提供优化前后的性能对比数据，以直观展示优化效果；提供运行过程中的详细运行日志。

第 11 条 严格遵守学术诚信，使用第三方内容需明确标注来源，严禁抄袭或侵权行为。

六、软硬件系统规范

第 12 条 参赛者在进行模型优化和部署时，需使用以下工具和环境：

1. 硬件环境：指定国产 X86 处理器及其加速卡，至少使用 2 张 K100-AI 卡（单卡显存 64GB、算力达到 192TFLOPS（FP16））。
2. 软件环境：Python 3.10、PyTorch 2.1.0（dtk24.04）、Transformers 4.47.1。

第 13 条 参赛者须确保提交的代码能够在大赛指定的硬件和软件环境中编译和运行，并通过提供的测试脚本和测试数据集进行性能测试。

七、大赛网站与参考资源

第 14 条 系统能力大赛主办方官网：https://pra.educg.net。参赛者可以通过该网站获取大赛的最新信息、报名参赛以及下载相关资料。

第 15 条 大赛网站提供多种软件开发工具及设计资料，包括但不限于下列内容：

1. DAS 软件使用说明。
2. 竞赛平台（代码提交方式、代码提交示例、竞赛平台使用）说明文档。
3. 性能基准测试程序。

八、注意事项

1. 提交的代码需通过主办方提供的硬件和测试脚本验证。
2. 优化过程中需确保模型功能及模块完整，不能影响模型的基本可用性。在固定专家数量的情况下优化，不能跳层。
3. 不允许使用外部硬件加速器或推理框架（如 vLLM），仅限指定国产 X86 处理器及 K100-AI 加速卡。

九、附录
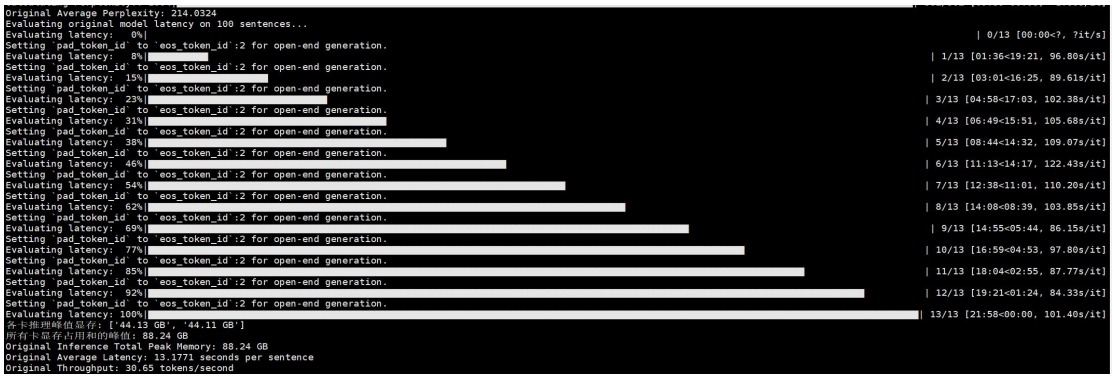
1. 模型下载链接：https://hf-mirror.com/mistralai/Mixtral-8x7B-v0.1
2. 测试数据集下载链接：https:// hf-mirror.com /datasets/Salesforce/wikitext
3. 基线模型 Mixtral-8x7B-v0.1 测试，结果如下：